TRABAJO PRÁCTICO INTEGRADOR

REDES NEURONALES (CNN Y RNN) CON KERAS

Cátedra de Inteligencia Artificial
integrante: Emanuel Rebechi

Módulo CNN:

Se utilizó una red neuronal convolucional (CNN) para resolver un problema de clasificación de imágenes. Para el desarrollo se utilizó el dataset Fashion-MNIST, compuesto por 70.000 imágenes en escala de grises de 28 × 28 píxeles.

Datos y partición:

Se conservaron las 10.000 imágenes oficiales de prueba y las 60.000 restantes se organizó en 600 lotes contiguos de 100 muestras. StratifiedGroupKFold, con cinco particiones y semilla 42, asignó 480 lotes al entrenamiento y 120 a validación, sin compartir lotes entre ambos conjuntos.

conjunto	muestras	uso
Entrenamiento	48.000	ajuste de peso
validación	12.000	selección del modelo
prueba	10.000	evaluación final

Los valores de píxel se transformaron de [0, 255] a [0, 1] y se agregó el canal de profundidad, por lo que cada entrada tiene forma 28 x 28 x 1.

Arquitectura:

Cada capa Conv2D aplica filtros de 3 x 3. En cada posición calcula la suma de productos entre el vecindario de entrada y los pesos del filtro, agrega un sesgo y aplica ReLU. El padding same conserva las dimensiones espaciales y el stride 1 examina todas las posiciones. MaxPooling de 2 x 2 reduce ancho y alto a la mitad y aporta tolerancia a desplazamientos pequeños.

Etapa del modelo elegido	Salida	Propósito
Entrada	28 × 28 × 1	Imagen normalizada
Conv2D 32 + ReLU	28 × 28 × 32	Bordes y texturas locales
MaxPooling	14 × 14 × 32	Reducción espacial

Conv2D 64 + ReLU	14 × 14 × 64	Patrones de mayor nivel
MaxPooling	7 × 7 × 64	Síntesis de características
Flatten + Dense 128	128	Integración global
Dense + Softmax	10	Probabilidad por clase

Activaciones y función de pérdida

ReLU se utilizó en las capas convolucionales y densas porque introduce no linealidad sin saturar su región positiva y permite aprender jerarquías de bordes, texturas y formas. La salida Softmax transforma los diez logits en una distribución de probabilidades que suma uno. Sparse categorical cross-entropy es adecuada porque cada imagen posee una sola etiqueta entera y penaliza que el modelo asigne baja probabilidad a la clase correcta.

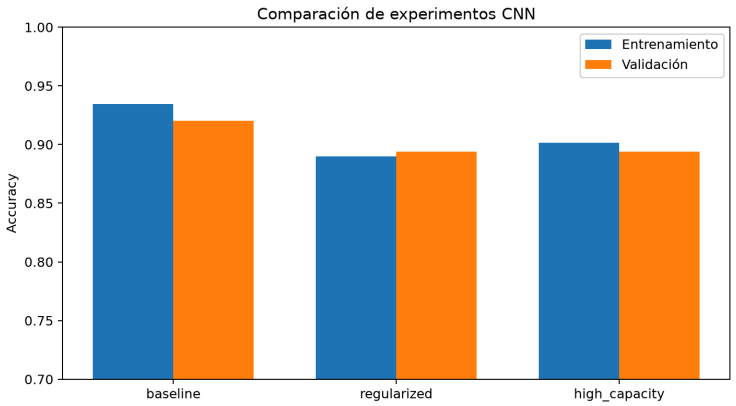
Las arquitecturas se mantuvieron comparables mediante la misma partición, semilla, tamaño de lote y cantidad máxima de épocas. Se variaron capacidad y regularización para observar el compromiso entre sesgo y varianza sin ajustar hiperparámetros sobre el conjunto de prueba.

Entrenamiento y control del ajuste

Los tres modelos se entrenaron durante un máximo de diez épocas, con lotes de 128 imágenes. Adam utilizó un learning rate inicial de 0,001 y la función de pérdida fue sparse categorical cross-entropy. EarlyStopping restauró los mejores pesos, ReduceLROnPlateau redujo el learning rate ante estancamiento y ModelCheckpoint conservó la menor pérdida de validación.

Comparación experimental

Modelo	Parámetros	Época	Train acc	Val acc	Val loss
Base	421.642	7	93.47 %	92.03 %	0.2229
Regularizada	94.346	9	89.00 %	89.39 %	0.2968
Mayor capacidad	250.058	9	90.13 %	89.40 %	0.2987



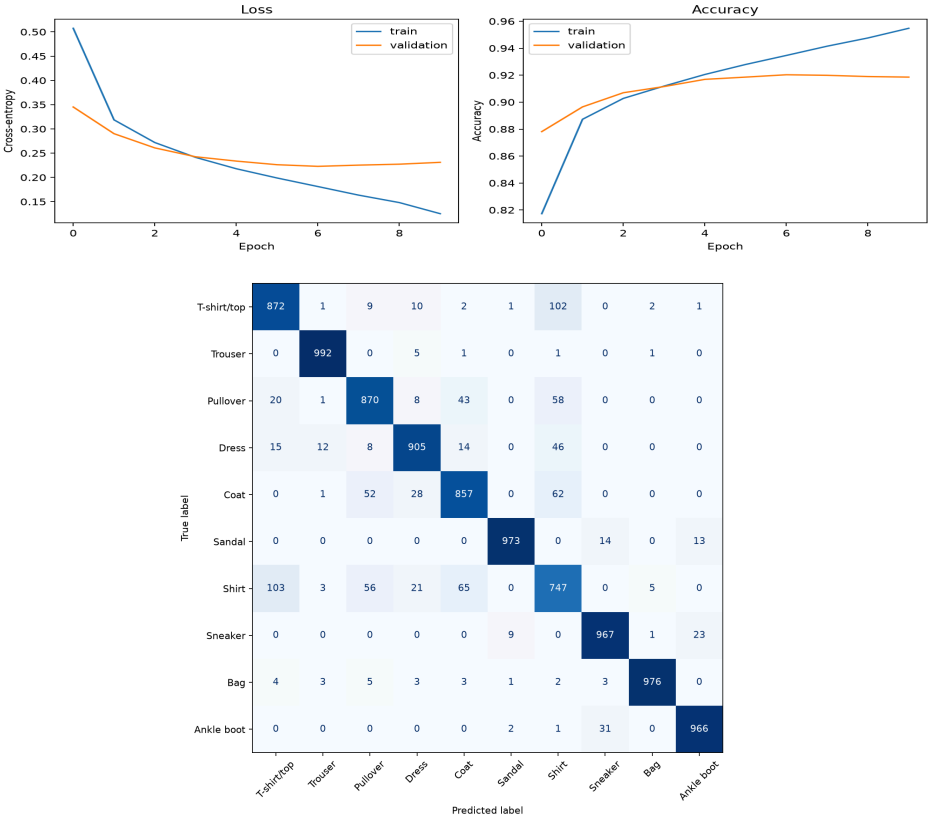
Análisis de sesgo y varianza

El modelo base alcanzó 93,47 % de accuracy de entrenamiento y 92,03 % de validación en la época 7. La brecha de 1,44 puntos indica varianza moderada, pero su pérdida de validación de 0,2229 fue la menor del estudio. En las tres épocas siguientes el entrenamiento continuó mejorando mientras la validación se estancó, evidencia de sobreajuste incipiente que justificó restaurar la época 7.

La variante regularizada combinó aumentación, Batch Normalization, Global Average Pooling y Dropout. La diferencia entre entrenamiento y validación fue mínima, pero ambas métricas quedaron cerca de 89 %, lo que señala mayor sesgo. La red de mayor capacidad tampoco compensó esa regularización: obtuvo 89,40 % de validación y mostró oscilaciones entre épocas. Se seleccionó el modelo base por la menor pérdida de validación, sin consultar el conjunto de prueba.

Evaluación final

El modelo seleccionado se evaluó una sola vez sobre el conjunto de prueba. Obtuvo una pérdida de 0.2467, accuracy de 91.25 % y F1 macro de 0.9127. La cercanía entre accuracy y F1 macro es consistente con las 1.000 muestras por clase del conjunto de prueba.



Rendimiento por clase

Trouser alcanzó F1 0,9856, Bag 0,9834 y Sandal 0,9799. La clase más difícil fue Shirt, con F1 0,7400, porque comparte siluetas y texturas con T-shirt/top, Pullover y Coat. Pullover y Coat obtuvieron F1 0,8700 y 0,8635. La matriz de confusión confirma que los errores se concentran en categorías visualmente similares y no en calzado o accesorios.

Módulo RNN:

Jena Climate reúne mediciones meteorológicas registradas entre 2009 y 2016. Se tomó una observación por hora y se usaron presión, temperatura, humedad relativa, velocidad y dirección del viento para pronosticar la temperatura seis horas adelante desde una ventana

de 72 horas. Las 70.092 observaciones se dividieron cronológicamente en 49.064 para entrenamiento, 10.514 para validación y 10.514 para prueba. La media y el desvío se calcularon solo sobre entrenamiento para evitar que información futura contaminara el ajuste.

Variable	Unidad	Aporte al pronóstico
Presión atmosférica	mbar	Cambios de masas de aire
Temperatura	°C	Estado reciente y variable objetivo
Humedad relativa	%	Relación con nubosidad y amplitud térmica
Velocidad del viento	m/s	Transporte y mezcla de aire
Dirección del viento	grados	Procedencia de las masas de aire

Ventanas y prevención de fuga temporal:

Cada ejemplo contiene 72 observaciones horarias consecutivas y su etiqueta es la temperatura ubicada seis pasos después de la última entrada. Las ventanas se desplazan de a una hora y mantienen el orden interno de la secuencia. La partición se realizó antes de normalizar y antes de construir ventanas, de modo que ninguna secuencia atraviesa el límite entre entrenamiento, validación y prueba. Mezclar las filas aleatoriamente habría permitido aprender información del futuro y producir métricas artificialmente optimistas.

Arquitectura y memoria temporal:

Se compararon celdas GRU y LSTM. Ambas incorporan compuertas que regulan qué información conservar u olvidar, creando rutas de gradiente más estables que una RNN simple durante la retropropagación a través del tiempo. GRU requiere menos parámetros que una LSTM equivalente y resultó ligeramente mejor en validación. Los modelos usaron Dropout 0,2, una capa Dense de 16 unidades, salida lineal, Adam con learning rate 0,001 y clipping de norma 1,0.

Capa del modelo final	Salida	Función
Entrada	72 × 5	Ventana multivariada normalizada
GRU 64	64	Memoria temporal con compuertas
Dense 16 + ReLU	16	Combinación no lineal de características
Dense lineal	1	Temperatura futura normalizada

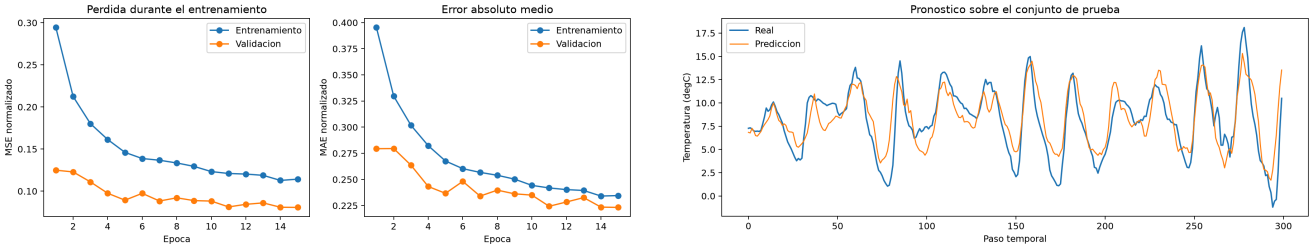
Retropropagación a través del tiempo:

Durante BPTT la red recurrente se despliega conceptualmente a lo largo de los 72 pasos y el error final se propaga hacia estados anteriores. En una RNN simple la multiplicación repetida por matrices recurrentes puede hacer que el gradiente tienda a cero o crezca sin control. Las compuertas de actualización y reinicio de GRU ofrecen caminos aditivos para conservar información útil y reducen la desaparición del gradiente. El clipping con norma máxima 1,0 limita explosiones ocasionales sin modificar la dirección global de la actualización.

Modelo	Parámetros	Época	Train MAE	Val MAE	Val RMSE
GRU 32	4.289	13	0.2494	0.2248	0.2880
GRU 64	14.689	15	0.2346	0.2232	0.2841
LSTM 32	5.409	14	0.2462	0.2282	0.2894

Evaluación y estabilidad predictiva

GRU 64 fue seleccionada exclusivamente por la menor MAE de validación (0.2232). En prueba obtuvo MAE 1.918 °C y RMSE 2.370 °C; el baseline persistente alcanzó 3.028 °C y 4.025 °C. La reducción fue de 36.7 % en MAE y 41.1 % en RMSE. Las curvas descendieron sin divergencia sostenida entre entrenamiento y validación. Las predicciones conservaron los ciclos y cambios de tendencia, aunque suavizaron algunos máximos y mínimos, principal limitación observada.



Análisis de errores y limitaciones:

La mejora frente a persistencia demuestra que el modelo aprovecha relaciones entre las cinco variables y no se limita a repetir la última temperatura. Sin embargo, las predicciones son más suaves que la serie real: los cambios rápidos y los extremos térmicos concentran los errores mayores. MSE favorece este comportamiento porque una estimación cercana al promedio reduce el costo de errores grandes, aunque puede atenuar picos. Como extensión se podrían comparar MAE o Huber como pérdidas, incorporar estacionalidad explícita y evaluar varios horizontes de pronóstico.

La comparación también muestra que una red más grande no garantiza una mejora proporcional. GRU 64 redujo la MAE de validación solo 0,0016 respecto de GRU 32, pero utilizó más del triple de parámetros. Por lo tanto, GRU 32 sigue siendo una alternativa razonable cuando importan memoria, velocidad de entrenamiento o tamaño del modelo.

Reproducibilidad:

Todos los experimentos usan semilla 42 y registran arquitectura, parámetros, historial por época, tiempos y métricas. EarlyStopping restaura los mejores pesos, ReduceLROnPlateau

disminuye el learning rate cuando la validación se estanca y ModelCheckpoint conserva cada candidato. Los archivos JSON y CSV permiten regenerar tablas y figuras sin volver a entrenar. El modelo elegido se exportó en formato Keras junto con los scripts y las dependencias declaradas.